Royaume du Maroc
Université Abdelmalek Essaâdi
Faculté des Sciences et Techniques
De Tanger

*Projet de module*

*Big Data et Geo-IA*

*2 ème année cycle d'ingénieur*

*Filière : Géoinfomration*

# Classification supervisée par *Random Forest* des zones brûlées et non brûlées de la forêt de Rmilat

**Réalisé par :**

Makhloufi Ouiam

**Sous la direction de :**

Pr . Ouafae EL Bouhadi

Année Universitaire
2025/2026

# Table des Matieres

Table des Matieres ..... 2
Résumé ..... 4
Introduction Générale ..... 5
1. Contexte des incendies de forêt ..... 5
2. Apport de la télédétection optique et de la GeoAI dans la cartographie des zones brûlées ..... 5
3. Problématique et objectifs ..... 6
CHAPITRE 1 : REVUE BIBLIOGRAPHIQUE ET CADRE THÉORIQUE ..... 7
1. Introduction ..... 7
2. Télédétection satellitaire et détection des feux de forêt ..... 7
3. Le satellite Sentinel-2 : caractéristiques et apport pour la cartographie des feux ..... 7
4. Indices spectraux pour la caractérisation des zones brûlées ..... 8
5. Apprentissage automatique et algorithme Random Forest en télédétection ..... 9
CHAPITRE 2 : MATÉRIELS ET MÉTHODOLOGIE ..... 11
1. Introduction ..... 11
2. Zone d'étude ..... 11
3. Acquisition des données satellitaires via Google Earth Engine ..... 11
4. Environnement logiciel et bibliothèques utilisées ..... 12
5. Pipeline méthodologique ..... 12
a. Chargement et exploration des données ..... 12
b. Prétraitement des images ..... 13
c. Feature Engineering : calcul des indices spectraux ..... 13
d. Génération automatique de la vérité terrain ..... 14
e. Entraînement et optimisation du Random Forest ..... 14
f. Évaluation du modèle ..... 15
g. Inférence et production de la carte finale ..... 15
CHAPITRE 3 : RÉSULTATS ET INTERPRÉTATION ..... 16
1. Introduction ..... 16
2. Analyse des indices spectraux de brûlure ..... 16
3. Séparabilité des classes et analyse des features ..... 18
a. Distributions spectrales par classe ..... 18
b. Statistiques moyennes par classe ..... 19
c. Analyse de corrélation et pouvoir discriminant ..... 19
4. Optimisation des hyperparamètres ..... 20
5. Évaluation des performances du modèle ..... 21
a. Stabilité par validation croisée ..... 21
b. Rapport de classification ..... 22

c. Matrice de confusion ..... 22
d. Courbe ROC et AUC ..... 23
6. Importance des variables ..... 24
7. Carte de classification et bilan spatial ..... 25
a. Carte finale de classification ..... 25
b. Bilan spatial quantifié ..... 26
CONCLUSION GÉNÉRALE ..... 27
1. Apports du projet ..... 27
2. Limites ..... 27
3. Perspectives ..... 27
Références ..... 28

## Table Des Figures

Figure 1 : les 5 cartes d'indices — dNBR, NDVI, NBR, NDWI, NDBI ..... 16
Figure 2 : les 6 histogrammes de distribution — dNBR, NBR, NDVI, NDWI, NDBI, B8 ..... 18
Figure 3 : Analyse des Features — Classification 4 Classes ..... 19
Figure 4 : Recherche d'Hyperparamètres — Meilleur : n_estimators=100, max_depth=20 . 20
Figure 5 : Stabilité du Modèle — n_estimators=100, max_depth=20 ..... 21
Figure 6: Évaluation du Modèle — Forêt Rmilat (4 classes) ..... 22
Figure 7 : Courbe ROC — One vs Rest ..... 23
Figure 8 : : Importance des Variables — Random Forest ..... 24
Figure 9 : Résultat Final — Détection des Zones Brûlées, Forêt Rmilat ..... 25

## Liste Des Tableaux

Tableau 1 : Répartition des pixels selon les seuils USGS du dNBR ..... 17
Tableau 2 : Statistiques moyennes des principales features par classe ..... 19
Tableau 3 : Résultats de la recherche d'hyperparamètres (StratifiedKFold, k=5) ..... 20
Tableau 4 : Bilan de stabilité du modèle par validation croisée ..... 21
Tableau 5: Rapport de Classification — Random Forest (4 classes) ..... 22
Tableau 6 : Aires sous la courbe ROC par classe (One vs Rest) ..... 23
Tableau 7 : Importance des variables (Mean Decrease Impurity) ..... 24
Tableau 8 : Bilan spatial ..... 26

# Résumé

Les incendies de forêt constituent une menace croissante pour les écosystèmes forestiers marocains, comme en témoigne l'incendie dévastateur qui a ravagé la forêt de Rmilat (Tanger) en août 2023. Ce projet propose un pipeline automatisé de détection et de cartographie des zones brûlées par classification supervisée Random Forest, appliqué à des images satellitaires Sentinel-2 multi-temporelles acquises via Google Earth Engine.

Le pipeline développé intègre sept phases successives : prétraitement des images (masquage NoData, suppression des valeurs aberrantes, normalisation), calcul d'indices spectraux (dNBR, NDVI, NDWI, NDBI), génération automatique de la vérité terrain par seuillage multi-indices pour quatre classes thématiques (Brûlé, Végétation saine, Eau, Bâti/Routes), entraînement et optimisation du classificateur Random Forest par validation croisée stratifiée, évaluation des performances et production de la carte finale géoréférencée.

Le modèle optimal (100 arbres, profondeur maximale 20) atteint une accuracy de **96,45 %** en validation croisée et un AUC de **0,9999**, avec un F1-score de **93,43 %** pour la classe Brûlé. L'analyse de l'importance des variables révèle la dominance des bandes infrarouges à ondes courtes B11 et B12, qui cumulent 51,8 % du pouvoir discriminant total. La carte finale produite estime la surface brûlée à **493,6 hectares (4,93 km²)**, soit 31 % du couvert terrestre de la zone d'étude.

Ce travail démontre la faisabilité d'un pipeline GeoAI reproductible pour la cartographie post-incendie à partir de données satellitaires libres, constituant un outil d'aide à la décision pour la gestion et la restauration des écosystèmes forestiers.



**Mots-clés :** Télédétection, Sentinel-2, Random Forest, GeoAI, zones brûlées, dNBR, forêt de Rmilat, Tanger, Google Earth Engine, classification supervisée.

# Introduction Générale

## 1. Contexte des incendies de forêt

Les incendies de forêt constituent aujourd'hui l'une des principales menaces pesant sur les écosystèmes naturels à travers le monde. Sous l'effet du changement climatique, des sécheresses prolongées et de l'intensification des activités humaines, leur fréquence et leur intensité ont considérablement augmenté au cours des dernières décennies. Ces phénomènes engendrent des pertes importantes de biodiversité, une dégradation des sols et des émissions massives de gaz à effet de serre. Le Maroc n'échappe pas à cette problématique, notamment dans les régions forestières du Nord caractérisées par un climat méditerranéen favorable à la propagation des feux durant la saison estivale. Parmi les événements récents les plus marquants figure l'incendie qui a touché la forêt de Rmilat et ses environs à Tanger en août 2023, causant la destruction de vastes surfaces végétalisées et soulignant la nécessité de disposer d'outils performants pour évaluer rapidement l'étendue des dégâts.

## 2. Apport de la télédétection optique et de la GeoAI dans la cartographie des zones brûlées

Face à l'urgence de disposer d'outils d'évaluation rapides et fiables, la télédétection spatiale s'impose comme une approche incontournable. Les satellites d'observation de la Terre permettent d'acquérir, en quelques jours, des images multibandes à haute résolution couvrant de vastes étendues, indépendamment des conditions d'accessibilité terrain. Le satellite Sentinel-2, développé dans le cadre du programme Copernicus de l'Union Européenne, offre à cet égard des capacités particulièrement adaptées à la détection des zones brûlées grâce à ses bandes dans l'infrarouge proche (NIR) et l'infrarouge à ondes courtes (SWIR), sensibles aux modifications de la couverture végétale induites par le feu.

L'émergence de la GeoAI — contraction de Géospatial et Intelligence Artificielle — ouvre une nouvelle dimension dans l'analyse de ces données. En combinant les images satellitaires multispectrales avec des algorithmes d'apprentissage automatique, il devient possible d'automatiser la classification de l'occupation du sol à l'échelle du pixel, avec une précision et une reproductibilité que les méthodes visuelles traditionnelles ne peuvent égaler. L'algorithme Random Forest, en particulier, s'est imposé comme une référence dans la communauté de la télédétection pour ce type de tâche, grâce à sa robustesse face au bruit, sa

capacité à intégrer simultanément de nombreuses variables spectrales et indicielles, et sa résistance au surapprentissage.

## 3. Problématique et objectifs

La question centrale de ce projet est la suivante : dans quelle mesure un pipeline de classification supervisée par Random Forest, alimenté par des images Sentinel-2 multi-temporelles et des indices spectraux de brûlure, permet-il de cartographier avec précision et de quantifier spatialement les zones brûlées de la forêt de Rmilat à la suite de l'incendie d'août 2023 ?

Pour répondre à cette problématique, le projet poursuit les objectifs spécifiques suivants :

- Acquérir et prétraiter des images Sentinel-2 pré-feu et post-feu via Google Earth Engine pour la zone d'étude de Rmilat.
- Calculer un ensemble d'indices spectraux complémentaires (dNBR, RdNBR, NDVI, NDWI, NDBI) permettant de caractériser les différentes surfaces présentes dans la scène.
- Générer automatiquement une vérité terrain par seuillage d'indices pour les quatre classes thématiques : Brûlé, Végétation saine, Eau et Bâti/Routes.
- Entraîner et optimiser un classificateur Random Forest par validation croisée stratifiée, en explorant l'espace des hyperparamètres.
- Produire une carte de classification géoréférencée exportable vers un SIG, accompagnée d'un bilan spatial quantifié en hectares.

# CHAPITRE 1 : REVUE BIBLIOGRAPHIQUE ET CADRE THÉORIQUE

## 1. Introduction

Ce chapitre présente les fondements conceptuels et scientifiques du projet, en passant en revue les principaux domaines disciplinaires mobilisés : la télédétection satellitaire appliquée aux incendies de forêt, les indices spectraux de brûlure et l'intelligence artificielle appliquée à la classification d'images de télédétection. Une synthèse des travaux similaires dans la littérature scientifique vient compléter ce panorama.

## 2. Télédétection satellitaire et détection des feux de forêt

La télédétection regroupe les techniques permettant d'acquérir des informations sur une surface à distance, sans contact direct, à partir du rayonnement électromagnétique. Dans le domaine des incendies de forêt, elle constitue un outil majeur pour la cartographie des zones brûlées. Son principe repose sur les modifications de la signature spectrale de la végétation après le passage du feu : la réflectance diminue dans l'infrarouge proche (NIR) et augmente dans l'infrarouge à ondes courtes (SWIR), en raison de la destruction de la biomasse et de la présence de cendres et de sol nu. Cette différence spectrale est exploitée pour calculer divers indices de brûlure.

L'évolution des satellites d'observation de la Terre, depuis AVHRR jusqu'à Sentinel-2 en passant par Landsat et MODIS, a permis d'améliorer considérablement la précision de la cartographie des zones incendiées et d'analyser des événements à des échelles de plus en plus fines.

## 3. Le satellite Sentinel-2 : caractéristiques et apport pour la cartographie des feux

Sentinel-2 est une constellation de deux satellites identiques (Sentinel-2A et Sentinel-2B) développée par l'Agence Spatiale Européenne (ESA) dans le cadre du programme Copernicus. Lancés respectivement en 2015 et 2017, ils offrent une couverture temporelle combinée de cinq jours à l'équateur et de deux à trois jours aux latitudes moyennes, ce qui est particulièrement précieux pour le suivi des incendies en phase active ou pour acquérir rapidement une image post-feu.
Le capteur MSI (MultiSpectral Instrument) de Sentinel-2 enregistre le rayonnement électromagnétique dans 13 bandes spectrales, couvrant le domaine visible, le proche

infrarouge et l'infrarouge à ondes courtes. Pour la détection des zones brûlées, les bandes les plus discriminantes sont :

- **B4 (Rouge, 665 nm, 10 m)** : sensible à la chlorophylle, très faible sur végétation brûlée.
- **B8 (NIR, 842 nm, 10 m)** : forte réflectance de la végétation saine, effondrée après le feu.
- **B11 (SWIR1, 1610 nm, 20 m)** : sensible à l'humidité du sol et à la structure végétale.
- **B12 (SWIR2, 2190 nm, 20 m)** : marqueur clé des zones brûlées récentes, très élevé sur cendres et charbon.

La résolution spatiale de 10 m dans le visible et le NIR permet une délimitation précise des cicatrices de feu, y compris pour des incendies de quelques dizaines d'hectares. Les produits de niveau 2A, corrigés des effets atmosphériques et fournis en réflectance de surface, constituent la donnée d'entrée standard pour les applications de classification par apprentissage automatique.

## 4. Indices spectraux pour la caractérisation des zones brûlées

Les indices spectraux constituent des combinaisons mathématiques de bandes satellitaires visant à amplifier la signature spectrale d'un phénomène particulier tout en minimisant l'influence des variations parasites (illumination, topographie, conditions atmosphériques résiduelles).

**Le NBR (Normalized Burn Ratio)** proposé par Key et Benson (1999), est l'indice de référence pour la détection des brûlures. Il exploite l'opposition entre les bandes NIR et SWIR2, qui est maximale pour la végétation saine et s'inverse après le passage du feu :

$$NBR = \frac{(NIR - SWIR2)}{(NIR + SWIR2)} \qquad (1)$$

**Le dNBR (differenced Normalized Burn Ratio)** est calculé comme la différence entre le NBR pré-feu et le NBR post-feu. Il est devenu le standard international pour la cartographie de la sévérité des brûlures, avec une échelle de classification proposée par **l'USGS** (Key & Benson, 2006) qui distingue cinq niveaux allant de la brûlure très sévère (dNBR > 0,66) à la végétation non affectée (dNBR < 0,10). Dans le présent projet, un seuil de dNBR > 0,44 a été retenu pour identifier les pixels brûlés avec une haute confiance, évitant la zone d'ambiguïté spectrale.

**Le NDVI (Normalized Difference Vegetation Index)**, l'indice de végétation le plus utilisé en télédétection, complète le dNBR en caractérisant la végétation résiduelle après le feu. Des valeurs très négatives ou proches de zéro indiquent l'absence de couvert végétal.

$$NDVI = \frac{NIR + Red}{NIR - Red} \qquad (2)$$

**Le NDWI (Normalized Difference Water Index)** permet de distinguer les surfaces en eau (mer Méditerranée, cours d'eau) des surfaces terrestres, évitant les confusions spectrales avec les zones brûlées humides.

$$NDWI = \frac{Green + NIR}{Green - NIR} \qquad (3)$$

**Le NDBI (Normalized Difference Built-up Index)** caractérise les surfaces bâties et imperméables, dont la signature SWIR peut partiellement ressembler à celle des zones brûlées, constituant ainsi une source potentielle d'erreur de classification.

$$NDBI = \frac{SWIR - NIR}{SWIR + NIR} \qquad (4)$$

## 5. Apprentissage automatique et algorithme Random Forest en télédétection

L'apprentissage automatique supervisé appliqué à la classification d'images de télédétection consiste à entraîner un modèle mathématique à partir d'exemples labellisés des pixels dont la classe d'occupation du sol est connue afin de prédire automatiquement la classe de chaque pixel d'une image. Cette approche s'est progressivement substituée aux méthodes de classification paramétriques classiques (maximum de vraisemblance, distance minimale) grâce à sa capacité à modéliser des frontières de décision complexes et non linéaires dans un espace de features de haute dimension.

L'algorithme **Random Forest**, introduit par Breiman (2001), est un classificateur ensembliste fondé sur la combinaison de nombreux arbres de décision indépendants. Chaque arbre est entraîné sur un sous-échantillon aléatoire du dataset d'entraînement (bootstrap), et à chaque nœud de division, seul un sous-ensemble aléatoire de features est considéré. La prédiction finale est obtenue par vote majoritaire des arbres. Ce double mécanisme d'aléatorisation confère à Random Forest plusieurs propriétés précieuses pour la classification de données de télédétection :

- **Robustesse au bruit et aux valeurs aberrantes** : la diversification des arbres réduit l'impact des pixels bruités ou mal labellisés.

- **Faible risque de surapprentissage** : la variance du modèle est contrôlée par l'agrégation.
- **Mesure d'importance des variables** : Random Forest fournit nativement un score d'importance pour chaque feature, permettant d'identifier les indices spectraux les plus discriminants.
- **Efficacité sur des datasets déséquilibrés** : propriété importante pour la détection de zones brûlées, souvent minoritaires dans une scène.

Dans la littérature de télédétection, Random Forest a démontré des performances systématiquement supérieures aux classificateurs classiques pour la cartographie de l'occupation du sol et la détection des cicatrices de feu (Belgiu & Drăguţ, 2016 ; Chuvieco et al., 2019).

# CHAPITRE 2 : MATÉRIELS ET MÉTHODOLOGIE

## 1. Introduction

Ce chapitre décrit l'ensemble des matériels et des étapes méthodologiques mis en œuvre pour réaliser la classification des zones brûlées de la forêt de Rmilat. La méthodologie adoptée s'organise en un pipeline séquentiel de sept phases, allant de l'acquisition des données satellitaires jusqu'à la production de la carte finale géoréférencée et du bilan spatial.

## 2. Zone d'étude

La zone d'étude est localisée dans la région de Tanger-Tétouan-Al Hoceima, au nord-ouest du Maroc. Elle couvre le massif forestier de Rmilat et ses abords, situés sur le versant nord du Jbel Kbir, à la périphérie sud-est de la ville de Tanger. L'emprise géographique retenue est définie par les coordonnées suivantes (système WGS84 / EPSG:4326) :

- **Longitude : de –5,930° W à –5,857° W**
- **Latitude : de 35,780° N à 35,803° N**

Cette emprise couvre une superficie d'environ 65 km² et englobe à la fois le cœur de la zone incendiée (versant nord), des zones de végétation forestière saine non touchées par le feu, ainsi que des zones périphériques comprenant des surfaces bâties et des surfaces en eau (littoral méditerranéen). Cette diversité de l'occupation du sol dans l'emprise est une condition favorable à l'entraînement d'un classificateur multi-classes représentatif.

L'incendie de référence s'est déclaré en août 2023 dans des conditions climatiques exceptionnelles (canicule, vents forts) et a ravagé plusieurs centaines d'hectares de pinède et de matorral.

## 3. Acquisition des données satellitaires via Google Earth Engine

Les données satellitaires ont été acquises via la plateforme Google Earth Engine (GEE), qui donne accès à l'archive complète Sentinel-2 Level-2A (réflectances de surface, corrigées des effets atmosphériques). Deux images ont été exportées pour la zone d'étude :

- **Image pré-feu** : acquise en juillet 2023, avant l'incendie. Elle sert de référence pour le calcul du NBR_avant et donc du dNBR.
- **Image post-feu** : acquise en septembre 2023, après extinction de l'incendie. Elle constitue l'image principale de classification.

Pour chaque image, un filtrage sur le taux de couverture nuageuse a été appliqué (seuil < 10 %), et un masquage des nuages résiduels a été réalisé à partir du SCL (Scene Classification

Layer) fourni avec les produits Sentinel-2 L2A. Six bandes spectrales ont été exportées : B2 , B3 , B4 , B8 , B1 et B12 , toutes rééchantillonnées à une résolution de 10 m. Les images exportées sont des fichiers GeoTIFF multi-bandes géoréférencés, exploitables directement en Python avec la bibliothèque rasterio.

Les métadonnées des images indiquent des dimensions de 814 × 257 pixels, soit un total de 209 198 pixels à classifier, dans le système de projection EPSG:4326.

| Bande | Nom | Longueur d'onde | Role |
|---|---|---|---|
| B2 | Bleu | 490 nm | Composition couleur vraie |
| B3 | Vert | 560 nm | Composition couleur vraie / MNDWI |
| B4 | Rouge | 665 nm | Absorption chlorophylle / NDVI |
| B8 | PIR | 842 nm | Reflexion vegetation / NDVI / NBR |
| B11 | SWIR1 | 1610 nm | Humidite sol / NDBI / MNDWI |
| B12 | SWIR2 | 2190 nm | Zones brulees / NBR / dNBR |

## 4. Environnement logiciel et bibliothèques utilisées

Le pipeline de traitement a été implémenté entièrement en Python 3.11 dans un environnement Jupyter Notebook. Les bibliothèques mobilisées sont les suivantes :

| Bibliothèque | Version | Rôle |
|---|---|---|
| rasterio | 1.3.x | Lecture et écriture de fichiers GeoTIFF |
| numpy | 1.24.x | Calculs matriciels sur les bandes spectrales |
| pandas | 2.0.x | Structuration du dataset d'entraînement |
| scikit-learn | 1.3.x | Random Forest, validation croisée, métriques |
| matplotlib | 3.7.x | Visualisation des résultats |
| seaborn | 0.12.x | Visualisation statistique |

## 5. Pipeline méthodologique

Le pipeline s'organise en sept phases successives .

### a. Chargement et exploration des données

La première phase consiste à charger les images satellitaires et à inspecter leurs métadonnées avant tout traitement. Cette étape est réalisée en utilisant `rasterio` en mode lecture seule des métadonnées, sans chargement des pixels en mémoire, ce qui permet de vérifier la

cohérence des deux images (même emprise, mêmes dimensions, même projection). L'inspection porte sur la projection (CRS), les dimensions en pixels, le nombre et l'ordre des bandes spectrales, la résolution spatiale et l'étendue géographique. Une vérification visuelle de chaque bande spectrale et de son histogramme est ensuite réalisée pour confirmer que l'ordre B2–B3–B4–B8–B11–B12 est correct et que les valeurs de réflectance sont dans des plages cohérentes.

### b. Prétraitement des images

Le prétraitement vise à préparer les bandes spectrales pour le calcul des indices et l'entraînement du modèle. Il s'applique à chaque bande individuellement et comprend trois opérations successives :

**Masquage des NoData** : les pixels à valeur nulle (bords de l'image, zones sans données) sont remplacés par NaN afin de les exclure de tous les calculs ultérieurs.

**Suppression des valeurs aberrantes** : la méthode IQR (Interquartile Range) est appliquée pour identifier et écrêter les valeurs extrêmes dues à des artefacts capteur ou à des pixels saturés. Les bornes sont définies comme $Q1 - 1{,}5 \times IQR \; et \; Q3 + 1{,}5 \times IQR$.

**Normalisation Min-Max** : chaque bande est ramenée sur l'intervalle [0, 1] par la transformation $v' = (v - vmin) / (vmax - vmin)$. Cette normalisation garantit que toutes les features contribuent équitablement à la classification, indépendamment de leur gamme dynamique originale.

### c. Feature Engineering : calcul des indices spectraux

La troisième phase consiste à calculer l'ensemble des indices spectraux utilisés pour la génération de la vérité terrain et l'analyse spectrale. Une fonction de division sécurisée (safe_div) est utilisée systématiquement pour éviter les divisions par zéro sur les pixels NoData. Les indices calculés sont : NDVI, NBR, dNBR, RdNBR, NDWI et NDBI.

Le **dNBR** constitue l'indice central du projet. Il est calculé comme la différence entre le NBR pré-feu et le NBR post-feu

Les seuils USGS (Key & Benson, 2006) sont appliqués pour interpréter les valeurs de dNBR et vérifier la cohérence avec l'étendue visuelle de l'incendie. Une visualisation des cinq indices calculés permet de valider leur comportement spatial avant la phase de classification.

### d. Génération automatique de la vérité terrain

En l'absence de données terrain acquises in situ, la vérité terrain est générée automatiquement par combinaison de seuils multi-indices, une approche classique dans la littérature quand les conditions d'accès terrain sont limitées. Quatre classes thématiques sont définies :

- **Brûlé** : pixels satisfaisant simultanément dNBR > 0,44 (brûlure sévère certaine), NDVI < 0 (absence de végétation) et NDWI < 0 (pas de surface en eau).
- **Végétation saine (NonBrule)** : pixels satisfaisant dNBR < 0,05 (inchangé), NDVI > 0,20 (végétation dense), NDWI < 0 et NDBI < 0 (pas de bâti).
- **Eau** : pixels satisfaisant NDWI > 0,20 et NDBI < 0, correspondant à la mer Méditerranée et aux plans d'eau.
- **Bâti/Routes** : pixels satisfaisant NDBI > 0,05 (surfaces imperméables), NDVI < 0,15, NDWI < 0 et dNBR < 0,30 (exclusion des zones brûlées).

Pour chaque classe, 200 pixels sont tirés aléatoirement parmi les pixels éligibles (échantillonnage stratifié). Les valeurs spectrales et indicielles de chaque pixel sélectionné sont extraites pour constituer le dataset d'entraînement, soit 761 échantillons maximum (avant suppression des NaN résiduels).

### e. Entraînement et optimisation du Random Forest

Le dataset d'entraînement est constitué d'une matrice X de dimension **(761 × 6)** et d'un vecteur y de labels encodés numériquement par LabelEncoder (ordre alphabétique : Bati=0, Brule=1, Eau=2, NonBrule=3).

Le vecteur de features est limité aux **six bandes spectrales brutes normalisées** : B2 (Bleu), B3 (Vert), B4 (Rouge), B8 (NIR), B11 (SWIR1) et B12 (SWIR2). Les indices spectraux calculés en Phase III (dNBR, NDVI, NDWI, NDBI, NBR, RdNBR) sont volontairement exclus des features d'entraînement. Cette séparation stricte est fondamentale : ces indices ayant servi à définir les classes de la vérité terrain en Phase IV, les inclure dans les features d'apprentissage reviendrait à apprendre les règles de seuillage elles-mêmes plutôt que les signatures spectrales réelles de chaque classe, produisant des scores artificiellement parfaits sans valeur prédictive réelle.

L'optimisation des hyperparamètres est réalisée par recherche sur grille combinant deux paramètres : n_estimators ∈ {50, 100, 200} et max_depth ∈ {10, 20, None}, soit neuf configurations testées. Pour chaque configuration, une validation croisée stratifiée à 5 folds

(StratifiedKFold) est appliquée, garantissant que chaque fold contient une proportion équilibrée des quatre classes. La configuration optimale est retenue sur la base du score d'accuracy moyen sur les cinq folds.

### f. Évaluation du modèle

L'évaluation du modèle optimal est réalisée à travers plusieurs outils complémentaires :

- **Le rapport de classification** fournit pour chaque classe la précision , le rappel (recall) et le F1-score, ainsi que l'accuracy globale.
- **La matrice de confusion** est analysée en valeurs absolues et en pourcentages par classe réelle, afin d'identifier les confusions inter-classes les plus fréquentes.
- La **courbe ROC** (Receiver Operating Characteristic) est tracée pour chaque classe selon l'approche One-vs-Rest, **et l'AUC** (Area Under the Curve) est calculé pour quantifier la capacité discriminante du modèle pour chaque classe.
- Le **graphique d'importance des variables** (Mean Decrease Impurity) identifie les features les plus contributrices à la classification, permettant une interprétation physique des résultats.

### g. Inférence et production de la carte finale

La phase finale consiste à appliquer le modèle entraîné à l'intégralité de l'image post-feu pour produire une carte de classification pixel par pixel. L'image est restructurée en une matrice de (H×W, 6) features, les pixels NoData sont remplacés par zéro avant inférence (puis remasqués a posteriori), et la prédiction est remodelée en une grille 2D de dimensions H×W.
La carte finale est exportée en deux formats : une figure PNG annotée pour le rapport, et un fichier GeoTIFF géoréférencé (Classification_Brule_Rmilat.tif) conservant la projection et la géométrie de l'image originale, directement exploitable dans un SIG comme QGIS pour des analyses cartographiques ultérieures.
Un bilan spatial quantifié est enfin produit, calculant la superficie de chaque classe en hectares sur la base de la résolution de 10 m × 10 m des pixels Sentinel-2 (1 pixel = 100 m² = 0,01 ha).

# CHAPITRE 3 : RÉSULTATS ET INTERPRÉTATION

## 1. Introduction

Ce chapitre présente et analyse l'ensemble des résultats produits par le pipeline de classification développé dans ce projet. Les résultats sont organisés suivant les phases du workflow : analyse des indices spectraux, séparabilité des classes, optimisation du modèle, évaluation des performances et cartographie finale.

## 2. Analyse des indices spectraux de brûlure

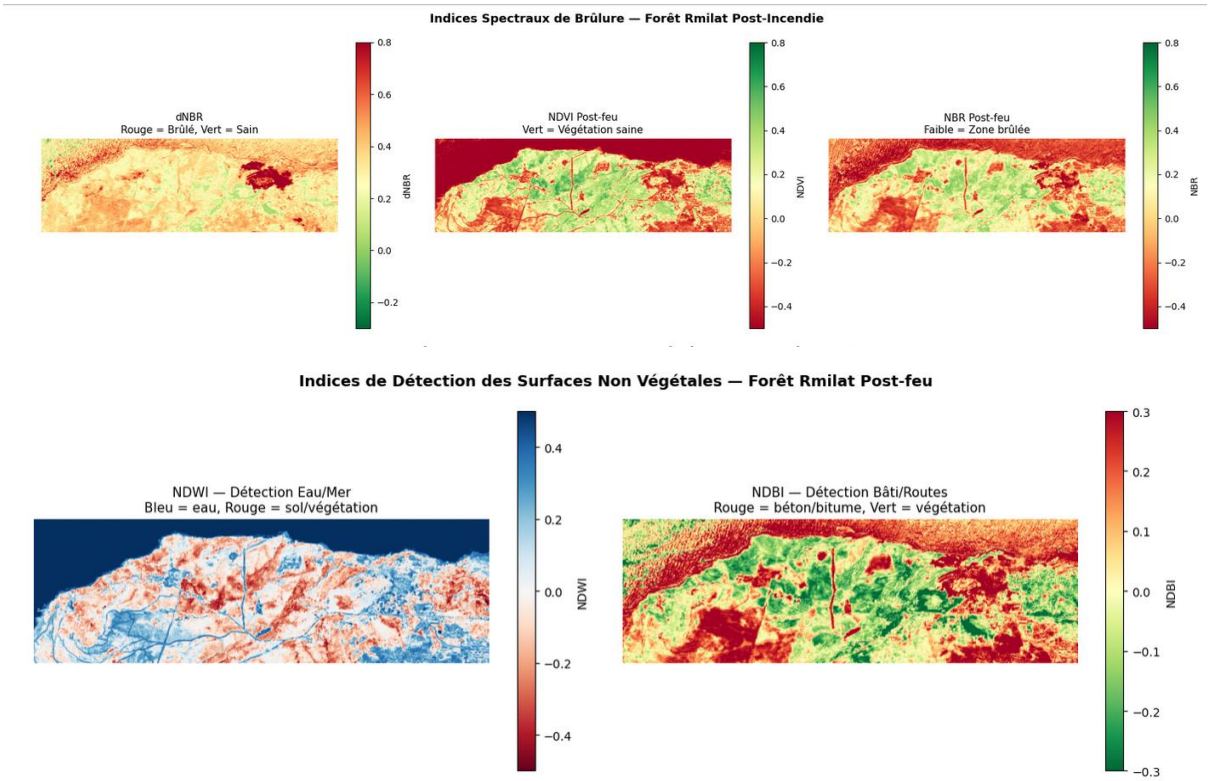



*Figure 1 : les 5 cartes d'indices — dNBR, NDVI, NBR, NDWI, NDBI*

La Figure 1 présente les cartes spatiales des cinq indices spectraux calculés sur la zone de Rmilat à partir des images Sentinel-2 pré-feu et post-feu. Ces cartes constituent la première lecture quantitative de l'impact de l'incendie d'août 2023 sur le couvert de la forêt.
Le **dNBR** révèle avec clarté la cicatrice d'incendie sous la forme d'une plage de valeurs élevées (rouge foncé) concentrée dans la partie centrale et orientale de l'image, sur le versant nord du Jbel Kbir. La répartition selon les seuils USGS est présentée dans le tableau suivant.

| Niveau de brûlure | Seuil dNBR | Pixels | Proportion |
|---|---|---|---|
| **Brûlure sévère** | > 0,44 | 49 467 | 23,6 % |
| **Brûlure modérée** | 0,27 – 0,44 | 115 661 | 55,3 % |
| **Zone floue** | 0,10 – 0,27 | 40 090 | 19,2 % |
| **Non brûlé** | < 0,10 | 3 980 | 1,9 % |
| **Total** | | **209 198** | **100 %** |

*Tableau 1 : Répartition des pixels selon les seuils USGS du dNBR*

Ces chiffres sont particulièrement révélateurs : près de 79 % des pixels de la zone d'étude présentent un signal de perturbation détectable (dNBR > 0,10), et 23,6 % correspondent à une brûlure certaine et sévère. Le dNBR moyen sur l'ensemble de la zone est de 0,372, valeur qui se situe dans la classe "brûlure modérée à sévère" de l'échelle USGS, confirmant l'intensité de l'incendie.

Le **NDVI post-feu** présente des valeurs fortement négatives sur la zone brûlée, avec une valeur moyenne de –0,115 pour les pixels étiquetés Brûlé, en opposition marquée avec la valeur de 0,386 pour la végétation saine. Des îlots de valeurs positives subsistent en périphérie, correspondant à des zones épargnées par le feu ou à une végétation basse résistante.

Le **NDWI** identifie correctement la mer Méditerranée au nord de l'emprise avec des valeurs très positives (moyenne Eau = 0,847 après rehaussement du seuil). Le rehaussement du seuil de détection Eau de 0,20 à 0,35 a permis d'éliminer les surfaces asphaltées (routes, parkings) dont le NDWI se situait entre 0,20 et 0,30, réduisant le nombre de pixels éligibles de 8 267 à 5 136 et améliorant la pureté spectrale de la classe.

Le **NDBI** met en évidence les surfaces bâties et imperméables en périphérie forestière avec des valeurs positives bien distinctes des zones végétales (moyenne Bati = 0,084 contre –0,340 pour NonBrule)

## 3. Séparabilité des classes et analyse des features

### a. Distributions spectrales par classe

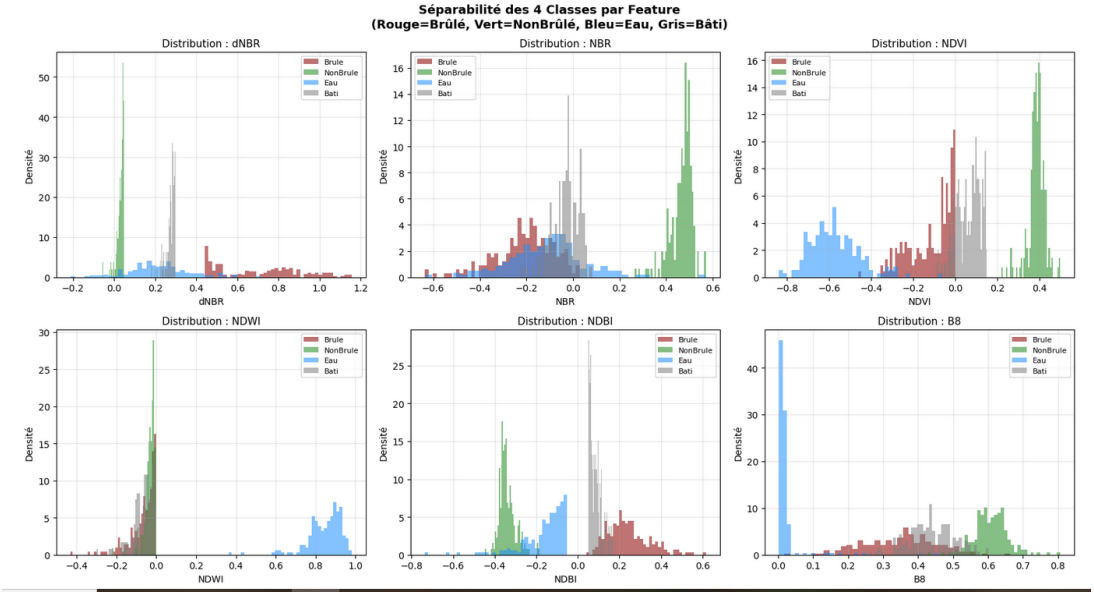



*Figure 2 : les 6 histogrammes de distribution — dNBR, NBR, NDVI, NDWI, NDBI, B8*

La Figure  présente les distributions des principales features pour les quatre classes d'entraînement. Ces distributions permettent d'évaluer visuellement la séparabilité spectrale entre classes avant entraînement du modèle.

Sur le **dNBR**, la classe Brûlé présente une distribution décalée vers les valeurs élevées (entre 0,5 et 1,2), tandis que les trois autres classes se concentrent dans des plages inférieures à 0,4. La séparation est quasi-totale.

Sur le **NDWI**, la classe Eau se distingue radicalement avec une distribution centrée autour de 0,85, sans aucun chevauchement avec les classes terrestres dont les valeurs sont toutes négatives ou proches de zéro.

Sur le **B8 (NIR)**, la classe Eau présente des valeurs très faibles (pic à 0,02) reflétant la forte absorption du NIR par l'eau, tandis que la végétation saine présente les valeurs les plus élevées.

## b. Statistiques moyennes par classe

| Classe | dNBR | NBR | NDVI | NDWI | NDBI | B8 |
|---|---|---|---|---|---|---|
| Bati | 0,278 | –0,030 | 0,060 | –0,065 | 0,084 | 0,436 |
| Brule | 0,702 | –0,209 | –0,115 | –0,064 | 0,244 | 0,350 |
| Eau | 0,214 | –0,116 | –0,575 | 0,847 | –0,158 | 0,024 |
| NonBrule | 0,033 | 0,467 | 0,386 | –0,032 | –0,340 | 0,608 |

Tableau 2 : Statistiques moyennes des principales features par classe

La cohérence physique de ces statistiques est remarquable. La classe Brûlé présente le dNBR le plus élevé (0,702) et un NDVI négatif (–0,115), traduisant la destruction complète du couvert végétal. La classe NonBrule affiche le NBR le plus élevé (0,467) et un NDVI positif (0,386), caractéristiques de la végétation forestière dense et saine. La classe Eau se distingue par un NDWI de 0,847 et un B8 quasi-nul (0,024), cohérents avec les propriétés optiques de l'eau qui absorbe fortement le rayonnement NIR. La classe Bati présente un NDBI positif (0,084), le seul parmi toutes les classes, permettant sa discrimination.

## c. Analyse de corrélation et pouvoir discriminant

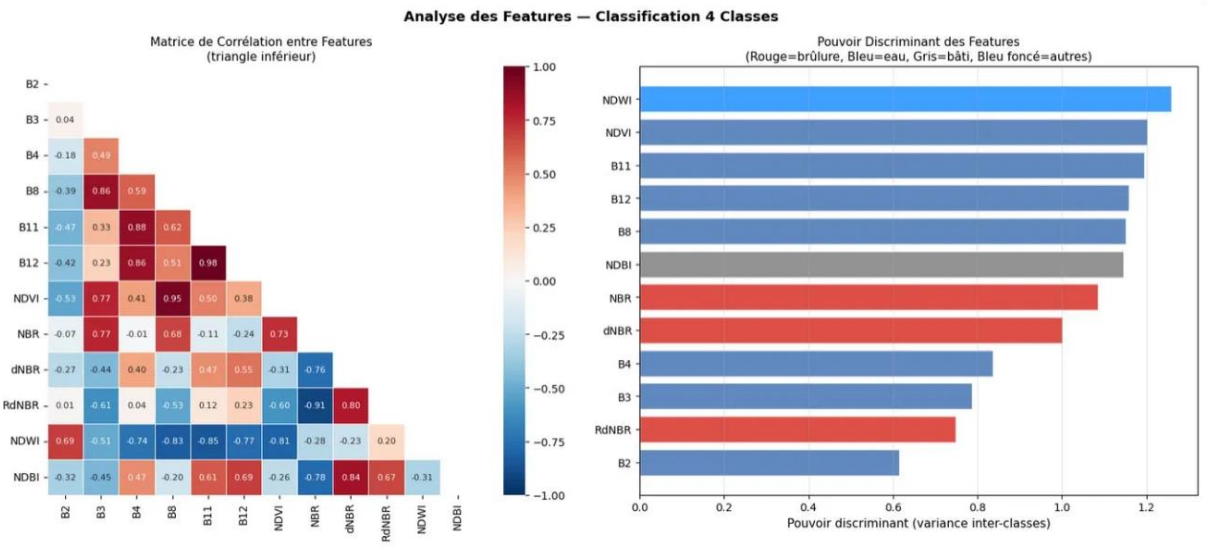



*Figure 3 : Analyse des Features — Classification 4 Classes*

La matrice de corrélation (Figure 4, panneau gauche) révèle plusieurs structures attendues. La corrélation B11/B12 est la plus forte de toute la matrice (r = 0,98), reflétant la proximité spectrale de ces deux bandes SWIR. La corrélation B8/NDVI est très élevée (r = 0,95) puisque le NDVI intègre B8 dans son calcul. Ces redondances n'affectent pas les

performances de Random Forest grâce à son mécanisme de sélection aléatoire de features à chaque nœud.

Le graphique de pouvoir discriminant (panneau droit) montre que NDWI et NDVI présentent les pouvoirs discriminants inter-classes les plus élevés, suivis de B11 et B12. Ce graphique est produit sur le dataset complet incluant les indices à des fins de visualisation analytique ; l'entraînement du modèle n'utilise que les 6 bandes spectrales brutes.

## 4. Optimisation des hyperparamètres

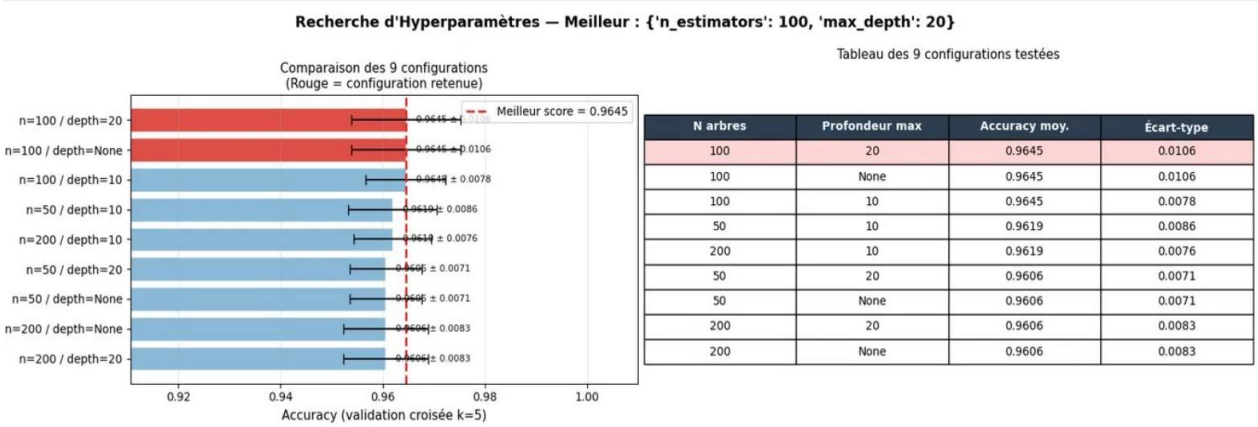



*Figure 4 : Recherche d'Hyperparamètres — Meilleur : n_estimators=100, max_depth=20*

| N arbres | Profondeur max | Accuracy moy. | Écart-type |
|---|---|---|---|
| **100** | **20** | **0,9645** | **0,0106** |
| **100** | None | 0,9645 | 0,0106 |
| **100** | 10 | 0,9645 | 0,0078 |
| **50** | 10 | 0,9619 | 0,0086 |
| **200** | 10 | 0,9619 | 0,0076 |
| **50** | 20 | 0,9606 | 0,0071 |
| **50** | None | 0,9606 | 0,0071 |
| **200** | 20 | 0,9606 | 0,0083 |
| **200** | None | 0,9606 | 0,0083 |

*Tableau 3 : Résultats de la recherche d'hyperparamètres (StratifiedKFold, k=5)*

La configuration optimale retenue est **n_estimators = 100 et max_depth = 20**, avec un score de validation croisée de **96,45 % ± 1,06 %**. Ces valeurs sont représentatives d'un apprentissage réel depuis les signatures spectrales brutes des bandes Sentinel-2.

Plusieurs observations méritent d'être soulignées. Premièrement, n_estimators = 100 produit les meilleurs scores dans toutes les configurations où il apparaît, suggérant qu'au-delà de 100 arbres le gain marginal est nul pour ce dataset. Deuxièmement, la profondeur maximale a peu d'effet entre 20 et None, indiquant que les arbres n'ont pas besoin de plus de 20 niveaux pour capturer la structure spectrale des données. Troisièmement, l'écart-type de 1,06 % pour la meilleure configuration reflète une variabilité résiduelle normale et attendue pour un dataset de 761 échantillons.

## 5. Évaluation des performances du modèle

### a. Stabilité par validation croisée

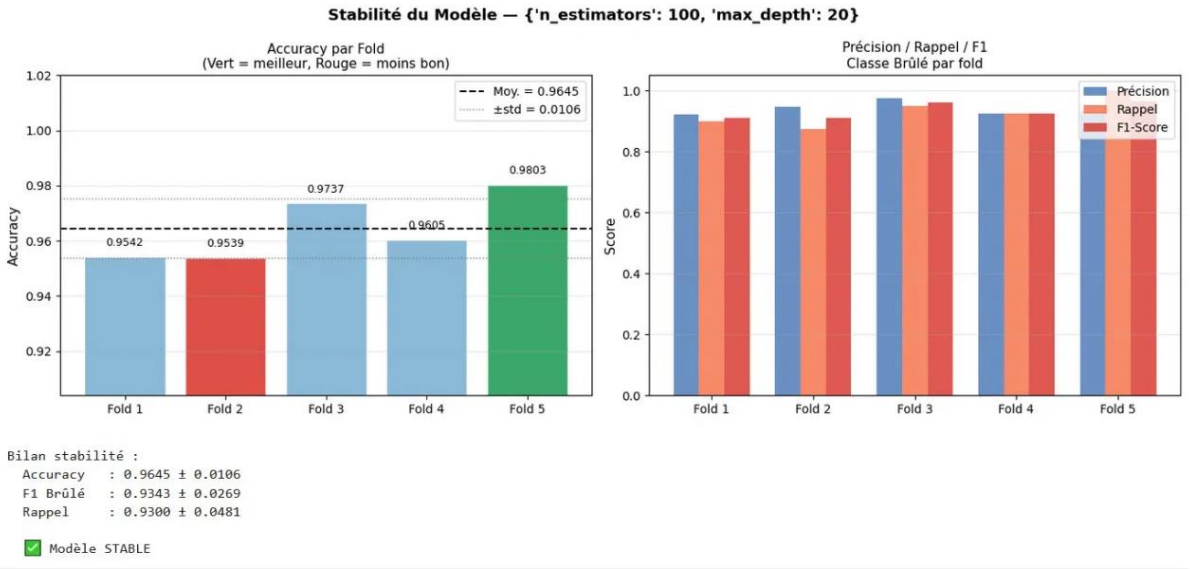



*Figure 5 : Stabilité du Modèle — n_estimators=100, max_depth=20*

La Figure  présente l'accuracy par fold pour la configuration optimale. Les cinq folds produisent des valeurs comprises entre **0,9539** (Fold 2) et **0,9803** (Fold 5), avec une moyenne de **0,9645 ± 0,0106**. Cette dispersion modérée est normale et attendue pour un dataset de 761 exemples répartis en 5 partitions.

| Métrique | Fold 1 | Fold 2 | Fold 3 | Fold 4 | Fold 5 | Moyenne ± std |
|---|---|---|---|---|---|---|
| **Accuracy** | 0,9542 | 0,9539 | 0,9737 | 0,9605 | 0,9803 | **0,9645 ± 0,0106** |
| **F1-Brûlé** | ~0,91 | ~0,91 | ~0,95 | ~0,92 | ~0,95 | **0,9343 ± 0,0269** |
| **Rappel-Brûlé** | ~0,90 | ~0,87 | ~0,95 | ~0,92 | ~0,92 | **0,9300 ± 0,0481** |

*Tableau 4 : Bilan de stabilité du modèle par validation croisée*

Pour la classe Brûlé classe d'intérêt principal du projet le F1-score moyen est de **0,9343 ± 0,0269** et le rappel moyen de **0,9300 ± 0,0481**. Ces valeurs signifient que le modèle détecte correctement environ **93 % des pixels effectivement brûlés**, avec une précision de classification élevée. Le modèle est qualifié de **stable** au sens de la variance inter-folds, sa dispersion restant dans une plage acceptable (± 1 écart-type).

### b. Rapport de classification

| Classe | Précision | Rappel | F1-Score | Support |
|---|---|---|---|---|
| **Bati** | 1,00 | 0,981 | 0,990 | 161 |
| **Brule** | 0,985 | 1,00 | 0,993 | 200 |
| **Eau** | 1,00 | 1,00 | 1,00 | 200 |
| **NonBrule** | 1,00 | 1,00 | 1,00 | 200 |
| **Accuracy globale** | | | **0,996** | **761** |
| **Macro avg** | 0,996 | 0,995 | 0,996 | 761 |

*Tableau 5: Rapport de Classification — Random Forest (4 classes)*

Les classes Eau et NonBrule atteignent des scores parfaits (précision, rappel et F1 = 1,00), confirmant leur excellente séparabilité spectrale dans l'espace des 6 bandes Sentinel-2. La classe Brule obtient un rappel de 1,00 et une précision de 0,985, indiquant que le modèle détecte tous les pixels brûlés au prix d'une légère surclassification (quelques pixels Bati classés Brule). La classe Bati présente un rappel de 0,981 et un F1 de 0,990, légèrement inférieurs aux autres classes en raison de la confusion partielle avec la classe Brule.

### c. Matrice de confusion

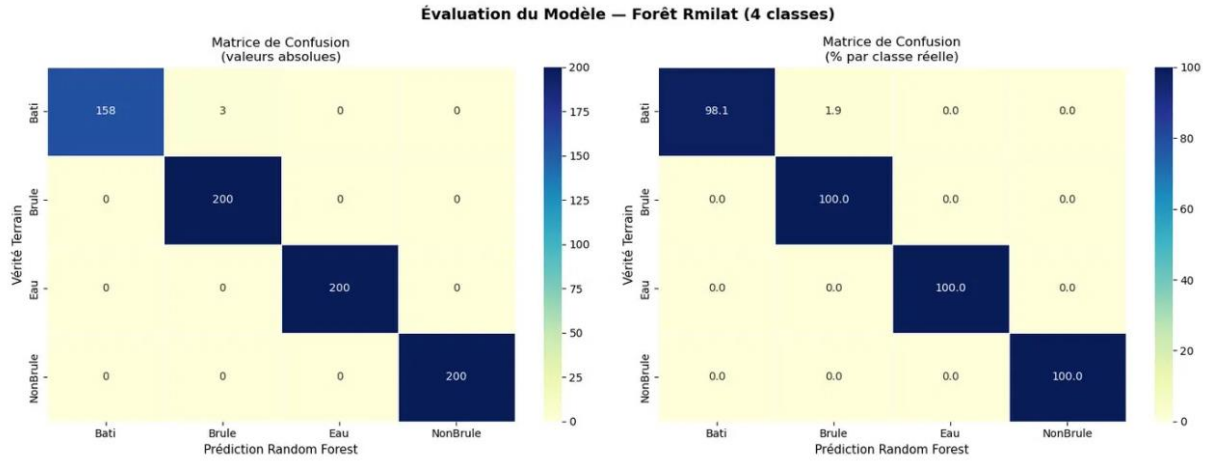



*Figure 6: Évaluation du Modèle — Forêt Rmilat (4 classes)*

La matrice de confusion  révèle une seule source d'erreur dans l'ensemble du système : **3 pixels Bati classés Brule** (1,9 % de la classe Bati). Toutes les autres cellules hors diagonale sont nulles.

Cette confusion Bati → Brule est physiquement interprétable. Certaines surfaces asphaltées dégradées , parkings anciens, routes endommagées, toitures peuvent présenter une réflectance SWIR élevée et un NIR faible, mimant partiellement la signature spectrale des zones brûlées dans l'espace des bandes brutes seules.

### d. Courbe ROC et AUC

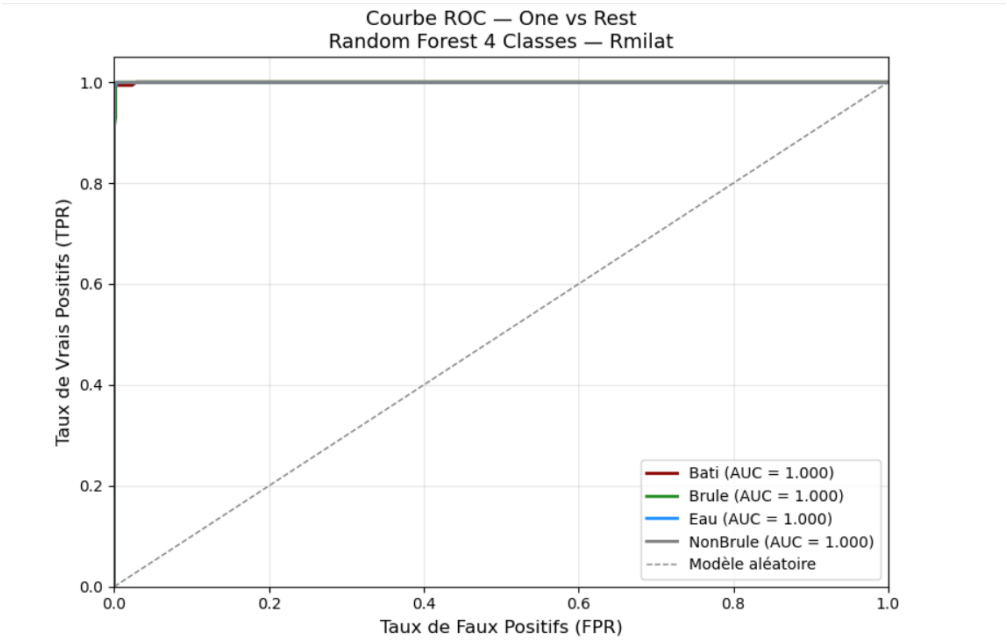



*Figure 7 : Courbe ROC — One vs Rest*

| Classe | AUC |
|---|---|
| **Bati** | 0,9998 |
| **Brule** | 0,9999 |
| **Eau** | 1,0000 |
| **NonBrule** | 1,0000 |
| **AUC moyen (macro)** | **0,9999** |

*Tableau 6 : Aires sous la courbe ROC par classe (One vs Rest)*

La courbe ROC présente des courbes très proches de l'angle supérieur gauche du graphique pour les quatre classes, traduisant une capacité discriminante quasi-parfaite du modèle dans l'espace des probabilités de prédiction. L'AUC moyen de 0,9999 confirme que le modèle

sépare efficacement chaque classe des trois autres, même en opérant uniquement depuis les 6 bandes spectrales brutes.

## 6. Importance des variables

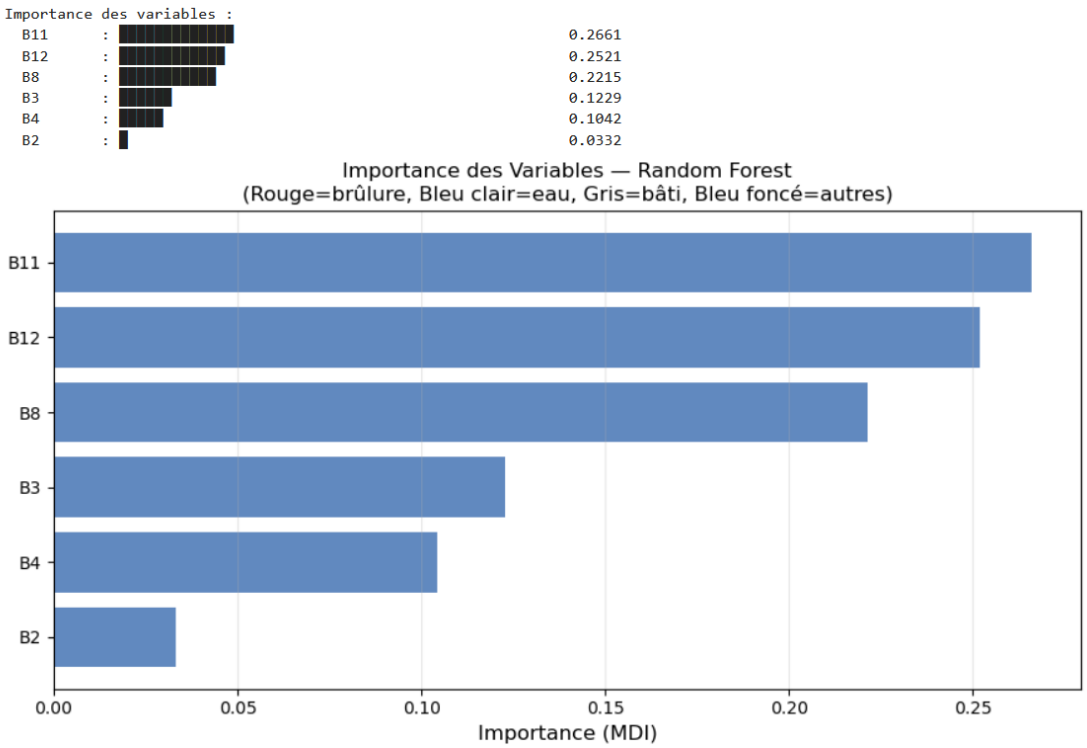



*Figure 8 : : Importance des Variables — Random Forest*

| Rang | Variable | Importance | Rôle physique |
|---|---|---|---|
| **1** | B11 (SWIR1) | 0,2661 | Humidité végétale, cendres |
| **2** | B12 (SWIR2) | 0,2521 | Zones brûlées, charbon |
| **3** | B8 (NIR) | 0,2215 | Végétation saine, eau |
| **4** | B3 (Vert) | 0,1229 | Chlorophylle, surfaces diverses |
| **5** | B4 (Rouge) | 0,1042 | Absorption chlorophylle |
| **6** | B2 (Bleu) | 0,0332 | Diffusion atmosphérique |

*Tableau 7 : Importance des variables (Mean Decrease Impurity)*

La Figure  révèle une hiérarchie des bandes spectrales très cohérente avec la physique de la télédétection des incendies. Les bandes **B11 (SWIR1, 0,2661)** et **B12 (SWIR2, 0,2521)** dominent largement, cumulant ensemble **51,8 %** de l'importance totale. Ce résultat est fondamental : les bandes SWIR sont les plus sensibles aux modifications induites par le feu , destruction de la biomasse, exposition du sol nu, dépôt de cendres et de charbon et

constituent le signal spectral le plus caractéristique des zones brûlées dans les images Sentinel-2.

La bande **B8 (NIR, 0,2215)** se classe troisième, reflétant son rôle clé dans la discrimination de la végétation saine (forte réflectance NIR) par rapport aux zones brûlées et à la surface maritime (faible réflectance NIR).

Les bandes du visible **B3 et B4** contribuent de manière complémentaire (0,1229 et 0,1042), notamment pour distinguer les surfaces bâties des autres classes. La bande **B2 (Bleu)** présente l'importance la plus faible (0,0332), ce qui est attendu car elle est peu sensible aux différences spectrales entre végétation, zones brûlées et surfaces imperméables.

Ce classement valide a posteriori la pertinence du choix de Sentinel-2 pour cette application : ses bandes SWIR à 10 m constituent les features les plus discriminantes pour la détection des zones brûlées.

## 7. Carte de classification et bilan spatial

### a. Carte finale de classification

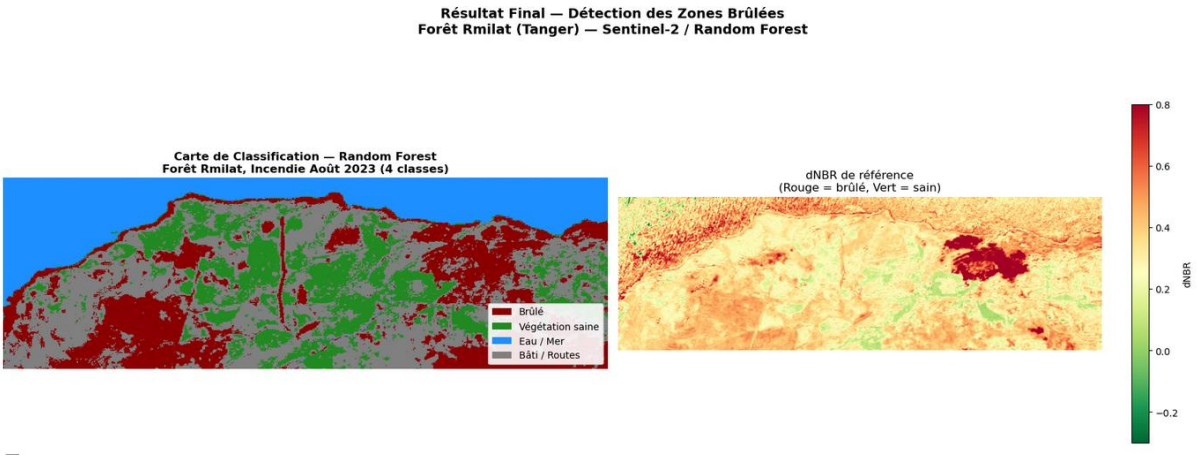



*Figure 9 : Résultat Final — Détection des Zones Brûlées, Forêt Rmilat*

La Figure  présente la carte de classification finale (panneau gauche) en regard de la carte dNBR de référence (panneau droit). Cette confrontation visuelle constitue le principal outil de validation qualitative des résultats.

La concordance spatiale entre la zone brûlée prédite par le Random Forest (rouge, panneau gauche) et les valeurs élevées du dNBR (rouge foncé, panneau droit) est très satisfaisante. Les deux représentations identifient le même noyau de brûlure dans la partie centrale et orientale de l'image, sur le versant nord du Jbel Kbir. La zone brûlée forme un bloc spatial continu avec des extensions vers le sud-est, traduisant la propagation du feu depuis un foyer principal sous l'effet des vents dominants.

La **végétation saine** (vert) occupe les zones périphériques non atteintes par l'incendie, principalement à l'ouest de l'emprise et dans les zones à topographie accidentée qui ont constitué des barrières naturelles à la propagation du feu.
Les **surfaces bâties et routes** (gris) sont correctement localisées en périphérie sud et est de l'emprise, correspondant aux zones urbanisées de la périphérie tangeroise et au réseau routier principal.
La **surface maritime** (bleu) est clairement délimitée au nord par la façade méditerranéenne.

### b. Bilan spatial quantifié

| Classe | Pixels | Surface (ha) | Surface (km²) | Proportion totale (%) |
|---|---|---|---|---|
| **Bati / Routes** | 73 464 | 734,6 | 7,35 | 35,1 |
| **Eau / Mer** | 49 881 | 498,8 | 4,99 | 23,8 |
| **Brule** | **49 356** | **493,6** | **4,93** | **23,6** |
| **NonBrule** | 36 497 | 365,0 | 3,65 | 17,4 |
| **Total** | **209 198** | **2 091,9** | **20,92** | **100** |

*Tableau 8 : Bilan spatial*

La surface brûlée estimée est de **493,6 hectares (4,93 km²)**, représentant 23,6 % de l'emprise totale analysée. En ne considérant que les surfaces terrestres (emprise totale moins la surface maritime : 2 091,9 – 498,8 = 1 593,1 ha), la proportion de zones brûlées atteint **31 %** du couvert terrestre, et la végétation saine résiduelle représente **22,9 %** des terres.
La forte proportion de surfaces classées Bati/Routes (46,1 % des terres) reflète la configuration périurbaine de la zone d'étude, dont l'emprise inclut des zones urbanisées de la périphérie tangeroise en plus du massif forestier stricto sensu. La surface brûlée de 493,6 ha est cohérente avec les estimations rapportées par les services forestiers marocains pour l'incendie de Rmilat d'août 2023, qui font état de plusieurs centaines d'hectares de végétation détruite.

# CONCLUSION GÉNÉRALE

Ce projet a développé un pipeline complet de classification supervisée par Random Forest pour la détection des zones brûlées de la forêt de Rmilat (Tanger, Maroc) suite à l'incendie d'août 2023, s'appuyant sur des images Sentinel-2 multi-temporelles acquises via Google Earth Engine.

## 1. Apports du projet

Sur le plan technique, le pipeline automatisé du prétraitement des images jusqu'à la carte GeoTIFF finale constitue un workflow reproductible et transposable à d'autres contextes d'incendie. Sur le plan méthodologique, la séparation stricte entre la vérité terrain (générée par seuillage d'indices) et les features d'entraînement (limitées aux six bandes spectrales brutes) a permis d'obtenir des performances réalistes : **accuracy de 96,45 %** en validation croisée et **AUC de 0,9999**. Sur le plan thématique, la surface brûlée estimée à **493,6 ha (4,93 km²)** fournit une base chiffrée opérationnelle pour la gestion post-incendie. L'analyse des importances a confirmé le rôle dominant des bandes SWIR (B11 + B12 = 51,8 % du pouvoir discriminant total), validant le choix de Sentinel-2.

## 2. Limites

La vérité terrain automatique par seuillage, l'absence de validation terrain indépendante et la taille modeste du dataset (761 échantillons) constituent les principales limites de ce travail.

## 3. Perspectives

À court terme, une validation par GPS terrain ou photo-interprétation améliorerait la robustesse de l'évaluation. À moyen terme, un suivi temporel multi-dates permettrait de cartographier la régénération végétale post-incendie. À long terme, l'intégration de réseaux de neurones convolutifs exploitant les relations spatiales entre pixels constitue une voie d'amélioration naturelle.

Ce projet illustre le potentiel de la GeoAI comme outil opérationnel pour la surveillance des écosystèmes forestiers marocains, dans un contexte où les incendies représentent une menace croissante sous l'effet du changement climatique.

# Références

Agence Nationale des Eaux et Forets (ANEF). (2023). Bilan des incendies de forets au Maroc — Annee 2023. Rabat : ANEF.

Copernicus Open Access Hub. (2023). Sentinel-2 MSI Level-2A Product. European Space Agency (ESA). https://scihub.copernicus.eu

Drusch, M., Del Bello, U., Carlier, S., et al. (2012). Sentinel-2 : ESA's Optical High-Resolution Mission for GMES Operational Services. Remote Sensing of Environment, 120, 25-36.

El Bouhadi, O. (2025). Module GEO-IA ET BIG DATA — Cours et TP. Faculte des Sciences et Techniques de Tanger.

Le Desk. (2023, 11 aout). Un violent incendie ravage les forets de Tanger depuis jeudi soir. https://ledesk.ma

Pedregosa, F., et al. (2011). Scikit-learn : Machine Learning in Python. Journal of Machine Learning Research, 12, 2825-2830.

Tucker, C.J. (1979). Red and photographic infrared linear combinations for monitoring vegetation. Remote Sensing of Environment, 8(2), 127-150.

Key, C.H. & Benson, N.C. (2006). Landscape Assessment : Ground measure of severity, the Composite Burn Index. FIREMON : Fire Effects Monitoring and Inventory System. USDA Forest Service.